Tugas 03 - Text and Web Mining Gloria Virginia, Ph.D.

1 Maret 2016

- 1. Hitung vector space similarity antara query dan document berikut ini dengan cara mengisi Tabel 1:
 - query (q): digital cameras
 - document (d): digital cameras and video cameras

Asumsi:

- Total dokumen, N = 10.000.000
- tf untuk query dan document: jumlah kemunculan terms
- wf untuk query dan document: menggunakan logarithmic term weighting
- idf weighting untuk query
- cosine normalization untuk dokumen
- Stopword: and

Tabel 1. Cosine Similarity

<i>T</i>	query						do	cument		~. u
Term -	tf	wf	df	idf	$q_i = wf$ -idf	tf	wf	$d_i = normalized wf$	q_i . d_i	Similarity
digital			10,000							
video			100,000							
cameras			50,000							

- 2. Hitung 2-top scoring documents (2 dokumen dengan nilai tertinggi), ketika
 - query (q): best car insurance
 - term frequency (tf) pada 3 dokumen (Doc1, Doc2, dan Doc3) dan 4 terms adalah sebagai berikut:

Term	Doc1	Doc2	Doc3	
car	27	4	24	
auto	3	33	0	
insurance	0	33	29	
best	14	0	17	

- Weighting schemes:
 - a). nnn.atc
 - b). ntc.atc

Untuk membantu Anda dalam menentukan 2-top scoring documents di atas, isilah Tabel 2 dan Tabel 3.

Tabel 2. Similarity Score antara query dan Doc1, Doc2, Doc3 dengan weighting scheme nnn.atc

Term		We	ight		Similarity Score			
	query	Doc1	Doc2	Doc3	query & Doc1	query & Doc2	query & Doc3	
car								
auto								
insurance								
best								

Tabel 3. Similarity Score antara query dan Doc1, Doc2, Doc3 dengan weighting scheme ntc.atc

Term		We	ight		Similarity Score			
	query	Doc1	Doc2	Doc3	query & Doc1	query & Doc2	query & Doc3	
car								
auto								
insurance								
best								